Reviewer-RAG: 근거 검증 기반 RAG의 정확도 향상 분석

위지우[O1], 김다은[2], 조해수[3], 이기용[4]
[1]숙명여자대학교 데이터사이언스전공, [2]숙명여자대학교 소프트웨어융합전공,
[3]숙명여자대학교 데이터사이언스전공, [4]숙명여자대학교 소프트웨어학부
jw201012@sm.ac.kr, daeunkim2002@naver.com, haesuj0520@sm.ac.kr, kiyonglee@sm.ac.kr

Reviewer-RAG: Improving Factual Accuracy of Retrieval-Augmented Generation through Evidence Validation

Wee Jiwoo[O1], Daeun Kim[2], Haesu Jo[3], Ki young Lee[4]
[1]Department of Data Science, [2]Department of Software Convergence,
[3]Department of Data Science, [4]Division of Computer Science
Sookmyung Women's University

요 약

기존 Retrieval-Augmented Generation(RAG)은 외부 지식을 검색하여 대규모 언어모델(LLM)의 사실적 정확도를 높이는 구조로 널리 활용되고 있다. 그러나 검색 단계에서 비관련 문서가 함께 추출되는 경우, 모델의 최종 답변에 오류가 발생한다는 한계가 존재한다. 본 연구에서는 RAG의 검색 결과를 한 단계 더 검증하는 Reviewer-RAG 구조를 제안한다. Reviewer-RAG는 검색된 근거를 Reviewer Agent가 1차적으로 평가하여 관련성이 낮은 근거를 제거하고, 유효한 근거만을 Answerer Agent에 전달한다. FEVER 데이터셋을 기반으로 실험한 결과, Reviewer-RAG는 기존 RAG 대비 정확도 3% 향상이라는 성능 개선을 보였다. 본 연구는 Reviewer 단계를 추가하는 간단한 방법만으로도 RAG의 사실적 일관성을 높일 수 있음을 보인다.

1. 서 론

대규모 언어모델(LLM, Large Language Model)은 자연어 생성 능력에서 뛰어난 성능을 보이고 있다. 하지만 모델이 학습 시점 이후의 정보를 반영하지 못하고 내부 파라미터에 저장된 제한된 지식에만 의존한다는 한계가 있다. 이로 인해, 외부 지식에 기반하지 않은 사실적 오류(factual hallucination)가 자주 발생한다.

이 문제를 해결하기 위해 제안된 Retrieval-Augmented Generation(RAG) 구조는 외부 지식베이스에서 질의와 관련된 문서를 검색한 뒤 이를 LLM의 입력으로 제공하여 사실적 근거를 보강하는 방식이다.[1]
하지만 RAG 구조는 검색기의 결과가 항상 정확하거나 관련성이 높은 문서만 포함하지 않기 때문에 retrieval noise로 인해 오히려 모델이 잘못된 정보를 학습하거나 부정확한 답변을 생성하는 경우가 발생한다.

* 본 연구는 2025년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업 지원을 받아 수행되었음 (2022-0-01087)

이에 본 연구에서는 기존 RAG 구조를 확장하여 CrewAI 프레임워크를 기반으로 근거 검증(Review) 단계를 추가한 Reviewer-RAG를 제안한다. Reviewer-RAG는 검색된 문서를 Reviewer Agent가 먼저 평가하여 관련성이 낮은 문서를 걸러내고 유효한 근거만을 Answerer Agent에 전달함으로써 생성 결과의 정확도와 신뢰성을 향상시킨다.

본 논문의 구성은 다음과 같다. 2장에서는 본 논문에서 사용한 기술인 RAG와 CrewAI에 대해 간략하게 설명한다. 3장에서는 본 논문에서 개발한 Reviewer-RAG 구조에 대해 설명한다. 4장에서는 실험 설계 방식에 대해 설명한다. 5장에서는 실험 결과를 제시하며 6장에서 결론을 맺는다.

2. 사전 지식 및 관련 연구

2.1 RAG

RAG는 2020년 Lewis 등(Lewis et al., 2020)에 의해 제안된 구조로, 대규모 언어모델(LLM)의 내부 지식 한계를 보완하기 위해 외부 지식 검색 과정을 입력 단계에 결합한 생성 기반 접근이다 [1]. 기존 LLM은 학습 데이터에 없는 최신 정보나 외부 지식을 반영하기 어렵지만, RAG는 질의에 대한 임베딩을 만들고 외부 문서 데이터베이스에서 벡터 유사도 기반으로 상위 k개의 관련 문서를 찾아 이를 LLM 입력에 통합함으로써 사실적 근거를 포함한 더

신뢰도 높은 응답을 생성한다.

다만 검색 결과에 무관하거나 오류가 섞이면 그 정보가 그대로 생성에 반영되어 사실적 오류(factual hallucination)를 유발할 수 있으므로, 전체 성능은 검색 품질에 크게 좌우된다. 이 문제를 줄이기 위해 검색 품질을 보정하거나 생성 결과를 사후 검증하는 여러 변형이 제안되어 왔으며, 예컨대 Self-RAG는 모델이 검색과 검증을 스스로 반복하는 절차를, Multi-Agent RAG는 여러 에이전트가 검색/생성/검증을 분담하는 협업 절차를 통해 품질을 높인다.

본 연구는 이러한 시도들의 복잡도를 낮추면서 효과적인 품질 개선을 얻기 위해 CrewAI 기반의 Reviewer-RAG를 도입하여, 검색 직후에 근거의 타당성과 관련성을 점검해 retrieval noise를 최소화하는 방향을 택했다.

2.2 CrewAI

CrewAI는 다중 에이전트 협업을 구현하는 오픈소스 프레임워크로, 서로 다른 역할과 목표를 가진 에이전트들이 각자의 프롬프트/도구/메모리를 바탕으로 중앙 오케스트레이터의 조율 아래 메시지를 주고받고 태스크를 순차 수행하도록 설계되어 있다 [4]. 핵심은 역할을 분리해 입력과 출력을 독립적으로 관리하고, 오케스트레이션을 통해 실행 순서와 상호작용을 자동화하며, 필요 시 에이전트를 쉽게 추가/교체해 복잡한 멀티스텝 태스크로 확장할 수 있다는 점이다. 본 연구에서는 CrewAI를 활용하여 검색 모듈(Retriever)과 두 에이전트(Reviewer, Answerer)를 느슨하게 결합한 구조를 구성했다. 특히 Reviewer를 검색 다음 단계에 배치해 반환 문서의 관련성과 신뢰도를 선제적으로 판별하고 부적절한 문서를 제거함으로써, Answerer가 보다 정제된 근거에 기반해 응답을 생성하도록 했다. 그 결과 FEVER 라벨 판정의 정확도와 사실적 일관성이 향상되며 전체 RAG 파이프라인의 신뢰성이 높아진다.

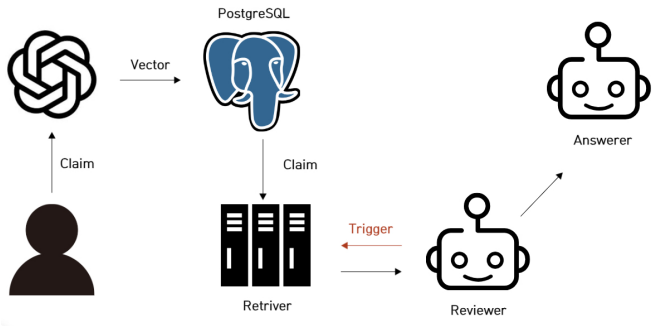


그림 1 제안하는 Reviewer-Rag 시스템의 전체 구조

3. 제안 구조: Reviewer-RAG

3.1 전체구조

본 시스템은 질의-근거-판단의 3단계 파이프라인으로 동작한다. 먼저 Retriever가 사용자의 질의를 OpenAI 임베딩 모델(text-embedding-3-small)로 벡터화하고, PostgreSQL의 pgvector 기반 벡터 데이터베이스에서 L2 거리 기준으로 상위 k개의 후보 문서를 검색한다. 이어서 Reviewer Agent가 검색 문서의 내용을 정밀히 분석해 주장 검증에 직접 도움이 되는 근거만 선별하며, 결과를 useful_ids, invalid_ids, all_good 필드를 갖는 JSON으로 반환한다. Reviewer가 all_good=False로 판정하면 동일한 k 값으로 즉시 재검색을 수행해 근거 후보를 갱신한다. 마지막으로 Answerer Agent가 Reviewer가 통과시킨 근거만 이용해 FEVER 라벨(SUPPORTS, REFUTES, NOT ENOUGH INFO)을 결정하고, GPT-4o-mini로 간결한 추론 형태의 응답을 생성한다.

3.2 벡터 데이터베이스 구축

벡터 저장소는 PostgreSQL 위에 pgvector 확장을 사용해 구성하였다. 테이블은 fever_embeddings를 사용하며 주요 컬럼은 id, sentence, embedding이다. 문서는 필요 시 문장 단위로 분할해 sentence에 저장하고, 각 sentence에 대해 OpenAI의 text-embedding-3-small로 생성한 임베딩을 별도 정규화 없이 그대로 embedding 컬럼에 저장한다. 검색 시에는 질의 임베딩을 동일 모델로 생성한 뒤 L2 거리로 정렬하여 상위 k개를 반환하며, 이때 sentence를 콘텐츠로 사용해 Reviewer 단계에 전달한다.

3.3 시스템 구현

전체 파이프라인은 Python 기반으로 통합되었고 오케스트레이션에는 CrewAI의 순차 실행을 사용한다. Retriever는 독립 함수로 벡터 DB를 질의해 후보 근거를 반환하고, CrewAI가 Reviewer와 Answerer 두 에이전트를 차례로 실행한다. Reviewer는 입력으로 받은 후보들의 ID와 내용을 검토해 useful_ids, invalid_ids, all_good를 산출하며, all_good=False일 경우 동일한 k로 재검색을 1회 트리거한다. Answerer는 Reviewer가 통과시킨 근거만을 받아 FEVER 라벨을 판정하고 GPT-4o-mini로 간결한 근거 중심의 답변을 생성한다. 이렇게 OpenAI 임베딩 + pgvector 검색과 에이전트 기반 근거 선별/판단이 유기적으로 결합되어 Reviewer-RAG 구조가 완성된다.

4. 실험설계

4.1 데이터셋

본 연구에는 FEVER(Fact Extraction and Verification) 데이터셋을 사용하였다. 각 샘플은 사실 주장(claim)과 정답 라벨(SUPPORTS, REFUTES, NOT ENOUGH INFO)로

구성되며, 실험에는 준비된 파일에서 랜덤으로 추출한 100개 샘플을 사용하였다.

4.2 평가지표

평가는 정확도(Accuracy) 하나로 측정하였다. 정확도는 예측된 라벨이 정답 라벨과 일치한 비율로 정의된다.

4.3 실험환경

서버는 로컬 PostgreSQL 환경에서 동작하며, fever_embeddings 테이블을 대상으로 임베딩 벡터와 질의 벡터 사이의 L2 거리를 기준으로 상위 k개 문서를 검색하였다. Reviewer와 Answerer는 GPT-4o-mini로 구성했고, 임베딩 생성에는 OpenAI text-embedding-3-small 모델을 사용하였다. 검색 상수는 k = 3, 재검색 횟수는 1회로 설정하였다.

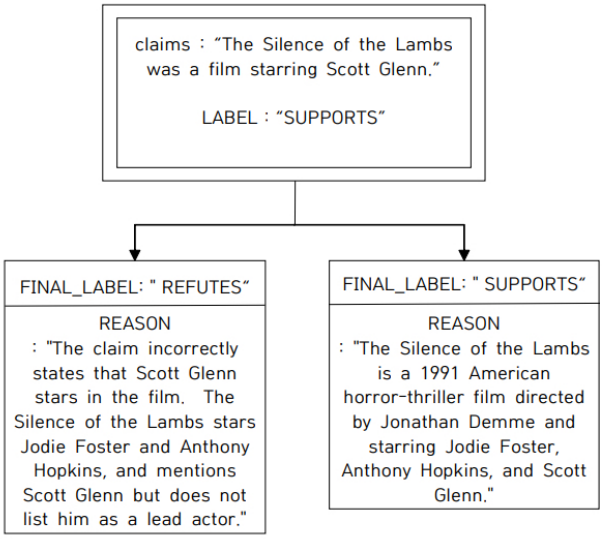


그림 2 (좌) 전통적 RAG 모델과 (우) 제안 모델의 claim 검증 결과 비교 예시

5. 실험결과

최종 결과, Reviewer-rag는 기존 RAG 대비 정확도가 약 3% 상승하였다. 질적 분석 결과, Reviewer-rag에서 인물명이나 작품명이 일치하지만 주장과 무관한 문서를 제거함으로써 Answerer 에이전트가 더 정확하고 일관된 논리적 판단을 내릴 수 있었다. Reviewer 단계 추가로 평균 처리 시간은 약 0.8초 증가했지만, 정확도 향상의 폭이 더 크기 때문에 더 효율적인 개선으로 평가된다.

6. 결론

본 연구에서는 기존 RAG의 한계를 보완하기 위해 Reviewer가 검색된 문서를 검증하고 Answerer가 이를 기반으로 최종 판단을 내리는 Reviewer-rag 구조를 제안하였다. FEVER 데이터셋 실험 결과 정확도가 약 3% 향상되었으며, 전반적으로 근거 정제와 응답의 사실성이 개선되는 경향을 확인했다.

참고 문헌

[1] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Kuzi, S., Stoyanov, V., Yih, W., & Riedel, S., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems, Vol. 33, No. 1, pp. 9459-9474, 2020.

[2] Asai, A., Kasai, T., Cheng, J. F., Wu, C. H., Zhang, R., & Hajishirzi, H., "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," arXiv preprint arXiv:2407.12819, 2024.

[3] Chang, C.-Y., Jiang, Z., Rakesh, V., Pan, M., Yeh, C.-C. M., Wang, G., Hu, M., Xu, Z., Zheng, Y., Das, M., & Zou, N., MAIN-RAG: Multi-Agent Filtering Retrieval-Augmented Generation, Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 1, -, 2607-2622, 2025.

[4] Moura, J. M. D., "CrewAI: Multi-Agent Collaboration Framework," GitHub Repository, (접속일자: 2025.10.20).